Dashboard Hành Động Cho Áp Dụng AI v2 và Memo quyết định

Lab Áp dụng AI Track 1 · Team AI Agent Gateway · Dự án: AI Agent Gateway · Repo: Day26_Track01_AI_Gateway

1. Phạm vi đã khoá

Sản phẩm AI	AI Agent Gateway: gateway tập trung định tuyến request tới LLM phù hợp theo loại tác vụ, policy và ngân sách
Nhóm người dùng chính	Nhân viên quản lý hạ tầng và tài nguyên AI tại doanh nghiệp có nhiều team phát triển AI cho nhiều domain nội bộ
Quy trình (4)	1) Đăng ký team và cấp quyền model. 2) Định tuyến request theo task, policy và ngân sách. 3) Xử lý lỗi provider và fallback. 4) Theo dõi chi phí, latency, usage và xử lý vượt ngân sách
Vấn đề quan sát được	Gateway chưa là đường gọi LLM mặc định của các team; chi phí vẫn đối soát thủ công và chưa có bằng chứng đo được rằng routing đúng theo từng loại tác vụ

2. Chẩn đoán

Năm câu hỏi mở đầu

Trục	Nhận định	Mức
Workflow	Gateway nằm ngoài đường gọi LLM mặc định của các team; chưa có bàn giao giữa team AI và đội hạ tầng	GỐC
Con người	Team AI chưa rõ khi nào nên đi qua gateway và ngại giao quyền chọn model vì không thấy lý do route	Liên quan
Sẵn sàng	Thiếu log traffic đã redaction, catalog giá cần chủ sở hữu và lịch cập nhật, policy theo data class chưa được Security duyệt	Liên quan
Tin cậy	Eval 95,3% là số tổng, chưa tách theo slice, chưa có QA mẫu và release gate chạy tự động	GỐC
Đo lường	Mới có metric cost/request và số request; chưa đo hành vi, thời gian quy trình và hard policy violation	Liên quan

Gartner Lite: tổ chức đã sẵn sàng chưa

Hạng mục	Nhận định	Kết quả
Hướng đi	Mục tiêu rõ: định tuyến theo task, policy, ngân sách; giảm chi phí LLM ≥15% trong pilot	ĐẠT
Dữ liệu	Chưa có log traffic đã redaction từ doanh nghiệp pilot, catalog giá chưa có owner cập nhật	THIẾU
Governance	Policy routing theo data class và chuẩn ISO 27001:2022 chưa được Security thống nhất	THIẾU
Vận hành	Chưa có owner chất lượng routing phía doanh nghiệp	THIẾU
Hấp thụ	Chưa có vòng phản hồi khi routing sai	THIẾU

Kết luận: pilot nhỏ ở chế độ shadow để sửa readiness; chưa nên rollout rộng.

Mollick: chia việc giữa người và AI

Vùng	Nội dung trong gateway
Người làm	Duyệt routing policy và ngân sách, xử lý ngoại lệ, đánh giá rủi ro, chịu trách nhiệm kết quả cuối (chủ hạ tầng AI)
AI hỗ trợ, người kiểm	Gateway phân loại task và đề xuất model; case mơ hồ hoặc thiếu metadata được người kiểm tra
AI tự động	Route task lặp lại, rủi ro thấp, có tiêu chí kiểm tra (common tasks, cost sensitive) trong phạm vi policy; hard policy luôn là quy tắc cứng, không để LLM quyết

ADKAR: người dùng kẹt ở đâu

Bước	Nhận định	Trạng thái
Awareness	Chưa rõ loại request nào nên đi qua gateway	NGHẼN
Desire	Ngại giao routing vì không thấy lý do chọn model và chi phí	NGHẼN
Knowledge	Chưa biết cách khai báo task và metadata	Cần làm
Ability	Chưa thực hành trong quy trình gọi LLM thật	Cần làm
Reinforcement	Chưa có phản hồi route sai và theo dõi hành vi mới	Cần làm

Kết luận: training là chưa đủ; cần lý do route kiểm chứng được, hướng dẫn và hỗ trợ ngay tại workflow.

Nguyên nhân gốc, framework và bằng chứng

Nguyên nhân gốc	Mô tả	Framework	Bằng chứng
Nguyên nhân gốc 1: Workflow và hấp thụ	Gateway chưa là bước chính thức trong quy trình gọi LLM của các team; chưa có bàn giao giữa team AI và đội hạ tầng; product boundary chưa chốt.	Mollick, Gartner Lite (Absorption)	PRD v1.0 (20/9/2026) ghi product boundary chưa chốt; survey và interview pain point đang thu thập.
Nguyên nhân gốc 2: Độ tin cậy	Chưa có bằng chứng đo được rằng routing đúng và an toàn theo từng slice, nên người dùng khó tin giao quyền chọn model cho gateway.	ADKAR (Desire), Gartner Lite (Readiness)	Eval hiện 95,3% là số tổng chưa tách 7 slice; release gate chưa chạy tự động. Case tham khảo: Morgan Stanley (độ tin cậy đi trước mở rộng), Klarna / Watson (số liệu nổi bật chưa đủ).

3. Cách làm mới

AS IS (trước)	TO BE (sau)
Team AI tự chọn model, gọi trực tiếp provider Khoá API rải rác ở nhiều team Đội hạ tầng đối soát chi phí cuối tháng bằng bảng tính Vượt ngân sách phát hiện muộn Lỗi provider xử lý thủ công	Team AI gọi một unified API Gateway phân loại task, lọc model theo policy, chọn model đạt chất lượng tối thiểu, trong giới hạn latency, chi phí thấp nhất Log lý do route, model, policy, chi phí QA mẫu hàng tuần, case mơ hồ chuyển người duyệt Dashboard cost, latency, usage; nút báo route sai

Ba thay đổi bắt buộc	Nội dung
Nguồn kiểm chứng	Mỗi quyết định route ghi model, policy áp dụng, lý do và chi phí; catalog giá có ngày cập nhật và người phụ trách
Người chịu trách nhiệm	Chủ hạ tầng AI duyệt routing policy và ngân sách; owner chất lượng routing phía doanh nghiệp; Lê Duy Bảo chịu trách nhiệm kết quả pilot
Khi AI không chắc chắn	Classifier confidence thấp hoặc thiếu metadata: route về model an toàn đáp ứng policy và gắn cờ review; provider lỗi: fallback; hard policy không còn model hợp lệ: chặn và chuyển người

Kiến trúc tin cậy	Nguồn	Trích nguồn	QA mẫu	Chuyển người	Phản hồi
Trong gateway	Catalog model, policy, giá có ngày	Log lý do route	Golden set 2 reviewer, replay suite	Case mơ hồ, hard policy bị chặn	Báo route sai, học lại

Yếu tố ứng dụng	Biểu hiện khi gateway được ứng dụng thật
Công việc	Gateway là bước gọi LLM trong quy trình của team pilot
Trách nhiệm	Có chủ hạ tầng AI duyệt policy và owner chất lượng routing
Kiểm soát	Log lý do route, QA mẫu, fallback và chuyển người khi AI sai
Hành vi	Team AI biết request nào đi qua gateway và khi nào cần ngoại lệ
Đo lường	Có mốc đầu, mục tiêu và hành động khi chỉ số xấu (mục 5)

Bốn điều kiện sẵn sàng: catalog giá và policy có người phụ trách và lịch cập nhật; quyền truy cập đúng người đúng mục đích; phạm vi dùng AI định nghĩa rõ ở 4 quy trình; chi phí, năng lực vận hành và quản trị được chốt với doanh nghiệp pilot.

4. Lộ trình 30 / 60 / 90 ngày

Giai đoạn	Mục tiêu	Việc chính	Owner	Dấu hiệu qua gate
0 đến 30 ngày	Chứng minh vấn đề	Vẽ AS IS / TO BE, khoá phạm vi, chốt product boundary qua survey và interview, chỉ định data owner, ghi mốc đầu	Lê Duy Bảo	Có mốc đầu cho 7 chỉ số, data owner được chỉ định, 1 doanh nghiệp đồng ý chạy shadow
31 đến 60 ngày	Chứng minh chất lượng	Bật log lý do route, QA mẫu theo 7 slice, hỗ trợ team khai báo metadata, theo dõi route sai và hành vi sử dụng	Đỗ Hoàng Nam Khánh, Nguyễn Anh Trí	0 vi phạm hard policy, task macro F1 ≥0,85, fallback thành công ≥95%
61 đến 90 ngày	Quyết định mở rộng	So với mục tiêu, chốt owner vận hành, kiểm tra governance với Security, quyết định mở rộng, sửa hoặc dừng	Lê Duy Bảo cùng CTO doanh nghiệp	Tiết kiệm chi phí ≥15% so với baseline, tỷ lệ request qua gateway ≥80%

5. Dashboard Hành Động v2

Chỉ số	Cấp · Tầng	Mốc đầu	Mục tiêu	Nguồn dữ liệu	Phụ trách	Khi chỉ số xấu
Tỷ lệ request của team pilot đi qua gateway	Workflow · Tầng 2 Hành vi	Đo tuần 1 từ log provider và log gateway	≥80% sau 60 ngày	Log gateway, log provider	Nguyễn Anh Trí	Phỏng vấn team còn gọi trực tiếp, tìm điểm vướng khi tích hợp
Thời gian đối soát chi phí LLM và xử lý sự cố provider mỗi tháng	Workflow · Tầng 3 Năng suất	Ghi nhận hiện trạng trong 2 tuần đầu	Giảm ≥50% so với mốc đầu	Ghi nhận thời gian của đội hạ tầng AI, log tác vụ	Trưởng đội hạ tầng AI của doanh nghiệp pilot	Xem lại cách làm, chỉnh báo cáo và cảnh báo trên dashboard
Tỷ lệ routing đúng trên bộ eval, tách theo 7 slice	Product · Tầng 4 Chất lượng	95,3% (eval hiện tại, số tổng)	Giữ ≥95,3%, task macro F1 ≥0,85, không regression theo slice	Bộ eval, golden set 2 reviewer, replay suite, LLMRouterBench	Đỗ Hoàng Nam Khánh	Tăng QA mẫu, chặn release, sửa classifier hoặc policy
Tỷ lệ vi phạm hard policy	Product · Tầng 4 Độ tin cậy	Đo trên replay suite đầu tiên	0%	Replay suite, báo cáo fault injection, audit log	Đỗ Hoàng Nam Khánh	Dừng release, sửa policy engine, review lại với Security
Tiết kiệm chi phí so với baseline	Product · Tầng 5 Giá trị	Chi tiêu LLM kỳ trước pilot	≥15% trong pilot, không cam kết ngoài pilot	Billing provider, log gateway	Lê Duy Bảo cùng FinOps	Chỉnh routing policy; không đạt sau 2 kỳ thì đổi phạm vi hoặc dừng
Tỷ lệ fallback thành công và case chuyển người đã xử lý	Product · Rủi ro, bàn giao	Ghi hiện trạng ở lần fault injection đầu	≥95% fallback thành công, 100% case hard policy không đủ model được chuyển người	Log lỗi, báo cáo fault injection	Nguyễn Anh Trí	Bổ sung xử lý fallback, thêm provider dự phòng
Gateway overhead P95	Product · Tầng 3 Năng suất	Đo gọi trực tiếp provider ở tuần 1	Ngưỡng nhóm chốt sau calibration	Log gateway	Nguyễn Anh Trí	Tối ưu, hoặc bật feature flag về gọi trực tiếp

6. Thay đổi so với v1 sau kiểm tra chéo

#	Dashboard v1	Dashboard v2	Lý do
1	Số request mỗi ngày qua gateway (activity, tầng 1)	Tỷ lệ request của team pilot đi qua gateway (hành vi, tầng 2)	Số request chỉ đếm hoạt động, không cho biết team có đổi cách gọi LLM hay không
2	Chỉ có product metric	Thêm workflow metric: thời gian đối soát chi phí và xử lý sự cố provider	Đo được quy trình của đội hạ tầng AI, nơi giá trị công việc thật sự thay đổi
3	Tỷ lệ AI làm đúng 95,3% là một số tổng	Tách theo 7 slice, thêm task macro F1 và điều kiện không regression	Số tổng che mất slice yếu như Hard policy, Provider failure, Adversarial
4	Số model kết nối; chưa có chỉ số an toàn	Bỏ số model kết nối, thêm tỷ lệ vi phạm hard policy 0% và tỷ lệ fallback thành công	Chỉ số kết nối là activity; hard policy và fallback là điều kiện để được mở rộng

Dashboard v1 gồm 5 chỉ số: Số request mỗi ngày qua gateway; Số model kết nối; Tiết kiệm chi phí so với baseline; Tỷ lệ AI làm đúng (eval, số tổng); Gateway overhead.

7. Memo quyết định

1. Vấn đề và nguyên nhân gốc	Gateway chưa là đường gọi LLM mặc định và chưa có bằng chứng đo được về độ đúng của routing theo slice. Nguyên nhân gốc: workflow và hấp thụ chưa thiết kế; độ tin cậy chưa kiểm chứng.
2. Framework và bằng chứng	Mollick và Gartner Lite cho chia việc và readiness, ADKAR cho điểm nghẽn Desire. Bằng chứng: PRD v1.0 (20/9/2026), eval 95,3% chưa tách slice, case Morgan Stanley và Klarna / Watson.
3. Thay đổi sau phản biện	Thay request mỗi ngày bằng tỷ lệ request qua gateway; thêm workflow metric thời gian đối soát; tách eval theo 7 slice; thêm hard policy violation và fallback success.
4. Quyết định	**Sửa**: Chạy shadow pilot nhỏ để sửa readiness và độ tin cậy, chưa rollout rộng, vì hướng đi đạt nhưng dữ liệu, governance và owner chất lượng routing còn thiếu.
5. Lý do, bước tiếp theo và owner	Bước tiếp theo: Lê Duy Bảo xin duyệt shadow mode trước 30/10/2026; Đỗ Hoàng Nam Khánh hoàn thành golden set 100 case trước 13/11/2026; Nguyễn Anh Trí dựng CI chạy eval và fault injection trước 06/11/2026.